

PREDICCIÓN DE ERUPCIONES VOLCÁNICAS MEDIANTE APRENDIZAJE PROFUNDO MULTIMODAL: Integración de datos GNSS y sísmicos de los volcanes Ubinas y Sabancaya, Perú

Jefry Erick Quispe Ramos
jefryerickq@gmail.com

June 23, 2025

Abstract

En el Perú nos enfrentamos a un riesgo constante debido a la actividad de los volcanes como: Ubinas y Sabancaya. En esta investigación, diseñamos un modelo de predicción eruptiva que utiliza redes neuronales profundas para analizar simultáneamente datos de deformación terrestre (GNSS) y registros sísmicos. En esta investigación estamos abordando tres problemas fundamentales: En primer lugar, la integración de series temporales multimodales usando arquitecturas LSTM combinadas con redes densas; en segundo lugar, la anticipación de explosiones volcánicas entre 24 y 72 horas (logrando 82.6% de precisión); y finalmente, la estimación de intensidad eruptiva mediante altura de columnas de ceniza (correlación de 0.036). El sistema, entrenado con optimizadores basados en gradiente (Adam, AdamW), mostró capacidad para identificar anomalías precursoras 12-36 horas antes de los eventos, además de revelar comportamientos distintivos entre ambos volcanes. Los resultados que obtuvimos nos indican que esta metodología puede mejorar los sistemas de alerta temprana en nuestra región andina del peru o de manera global con datos requeridos, superando las limitaciones de los modelos tradicionales que analizan una sola variable.

Palabras clave: Deep Learning, GNSS, predicción volcánica, Ubinas, Sabancaya, sistema de alerta temprana.

1 Introducción

En el sur del Perú volcanes como Ubinas y Sabancaya representan amenazas importantes para nuestra población, que también se enmarcan dentro de los 800 millones de personas que viven en zonas de riesgo volcánico a nivel global (1). Debido a su ubicación en el Cinturón de Fuego del Pacífico, el arco volcánico andino concentra aproximadamente el 60% de los volcanes activos de Sudamérica. Esta alta densidad de sistemas volcánicos, sumada a condiciones socioeconómicas y geográficas complejas, plantea retos significativos para la reducción del riesgo en países como Perú. (2).

El caso peruano destaca por la actividad recurrente de los volcanes Ubinas ($16^{\circ}22'S$, $70^{\circ}54'W$, 5,672 msnm) y Sabancaya ($15^{\circ}47'S$, $71^{\circ}51'W$), ambos ubicados en el arco volcánico sur del país. El Ubinas, considerado el volcán más activo del Perú, ha presentado 27 episodios eruptivos documentados desde el siglo XVI (3). Por su parte, el Sabancaya mantiene un estado eruptivo continuo desde 2016, con emisiones que superan regularmente los 3 km de altura (4).

En la actualidad la vigilancia de volcanes activos se basa en el análisis simultáneo de múltiples parámetros, como cuando hacen uso de redes de sensores sísmicos capaces de identificar señales asociadas al movimiento de fluidos magmáticos o hidrotermales en profundidad (5), geodesia satelital (GNSS-InSAR) para medir deformaciones del terreno (6), y sensores remotos para seguimiento de emisiones gaseosas (7).

En este contexto, los avances en inteligencia artificial están revolucionando el análisis de

datos volcánicos. Las técnicas de *deep learning* han demostrado particular eficacia en diversas aplicaciones, como la clasificación automática de señales sísmicas volcánicas (8), la detección de patrones precursores en series temporales multiparamétricas (9), y el modelado predictivo de actividad eruptiva (10). Estas metodologías están permitiendo avances significativos en la interpretación de grandes volúmenes de datos de monitoreo.

2 Marco Teorico

La intrusión de magma en profundidad modifica el estado de esfuerzos de la corteza, generando deformaciones superficiales detectables mediante estaciones GNSS de alta precisión. Estas variaciones milimétricas permiten inferir procesos como inflación de reservorios magmáticos, migración de diques o cambios en la permeabilidad del sistema volcánico.

Modelos de aprendizaje profundo, como las redes LSTM y CNN, han demostrado capacidad para capturar patrones complejos en datos geodésicos. Las LSTM son efectivas para analizar series temporales prolongadas, al mantener información relevante en su memoria interna; las CNN, por su parte, extraen características locales útiles en representaciones espaciales de deformación.

El entrenamiento se realiza mediante optimización basada en gradientes, siendo Adam y su variante AdamW especialmente útiles en contextos ruidosos como el monitoreo volcánico. AdamW mejora la generalización al desacoplar la regularización L2 del cálculo del gradiente, permitiendo una mejor adaptación a datos no estacionarios.

3 Metodos

3.1 Datos Utilizados

Dataset 1: Deformación GNSS Fuente: Catálogo oficial del Instituto Geofísico del Perú (IGP) (11). Período: 2023-2025. Variables: Componentes Este, Norte, Vertical (mm).

Dataset 2: Explosiones de Ceniza Fuente: Observatorio Vulcanológico del INGEMMET (12). Eventos registrados: 34,310.

Dataset 3: Eventos Sísmicos Fuente: Red Sísmica Nacional del IGP (13). Registros: 726,672.

3.2 Preprocesamiento de Datos

Limpieza de datos: Se procesaron los 3 datasets utilizados para optimizar su uso en el método aplicado, eliminando valores atípicos y usando valones necesarios para el metodo.

Ingeniería de características: Se calcularon métricas derivadas incluyendo:

$$D = \sqrt{E^2 + N^2 + V^2} \quad (\text{Magnitud de deformación}) \quad (1)$$

$$\dot{D} = \frac{dD}{dt} \quad (\text{Velocidad de deformación}) \quad (2)$$

$$\ddot{D} = \frac{d^2D}{dt^2} \quad (\text{Aceleración}) \quad (3)$$

Adicionalmente agregamos características sísmicas diarias como conteos de eventos y energía liberada por tipo de señal sísmica.

Creación de ventanas temporales: Utilizamos el diseño temporal de ventanas de entrada de 14 días consecutivos de datos GNSS con horizontes de predicción de 24, 48 y 72 horas. Las ventanas se construyeron con un solapamiento de 24 horas para maximizar la utilización de los datos disponibles.

3.3 Arquitectura del Modelo

Arquitectura Multi-modal Propuesta:




Figure 1: Arquitectura neural multi-modal propuesta. La rama GNSS procesa series temporales de deformación mediante LSTM, mientras que en la rama sísmica procesamos características agregadas. Ambas se combinan para predicción de explosiones e intensidad.

Componentes del modelo:

Rama GNSS: La arquitectura procesa secuencias temporales de 14 días con tres variables (componentes Este, Norte y Vertical). La red contiene dos capas LSTM con 128 y 64 unidades respectivamente, intercaladas con una capa Dropout (tasa 0.2) para regularización. Esta rama genera un vector de características temporales de 64 dimensiones que codifica los patrones de deformación.

Rama Sísmica: Este módulo procesa características sísmicas agregadas diariamente, incluyendo conteos por tipo de evento (VT, VD, ST, TO), energía liberada y parámetros espectrales. La estructura consiste en capas densas de 32 y 16 neuronas con activación ReLU, seguida de Dropout (tasa 0.3) para prevenir sobreajuste, produciendo un vector de características de 16 dimensiones.

Fusión y predicción: Los vectores de ambas ramas (64 + 16 dimensiones) se concatenan formando un espacio de características combinado de 80 dimensiones. Este tensor pasa por dos capas densas (64 y 32 neuronas, ReLU) antes de bifurcarse en dos salidas: una capa sigmoide que estima la probabilidad de explosión volcánica y una capa lineal para la regresión de altura de columna eruptiva. Esta arquitectura multimodal permite la interacción sinérgica entre señales geodésicas y sísmicas.

3.4 Entrenamiento y Optimización

Configuración de entrenamiento: Optimizador: Adam ($lr = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$). Función de pérdida: Combinada (binary crossentropy + MSE). Batch size: 32. Épocas: 100 con early stopping. Validación: 20% de los datos. Regularización: L2 ($\lambda = 0.01$) + Dropout.

Técnicas de optimización implementadas: Learning rate scheduling (ReduceLROnPlateau). Gradient clipping (norm=1.0). Batch normalization. Data augmentation temporal.

4 Resultados

4.1 Rendimiento del Modelo

El modelo mostró un accuracy aparentemente alto (82.6%) pero reveló graves limitaciones en el análisis detallado:

Métrica	Valor
Accuracy	0.826
AUC-ROC	0.650
Correlación altura	0.036
Precision (No Explosión)	0.76
Recall (No Explosión)	0.20
F1-score (No Explosión)	0.32

Table 1: Métricas de rendimiento que evidencian el sesgo hacia la clase mayoritaria.

4.2 LOSS - Training and Validation

Muestra la evolución del *loss* durante el entrenamiento. Se observa una disminución constante del *training loss*, mientras que el *validation loss* deja de mejorar alrededor de la época 30 y luego muestra un leve aumento. Esto sugiere un posible sobreajuste a partir de esa etapa del entrenamiento.




Figure 2: Pérdida (*Loss*) durante el entrenamiento y validación.

4.3 Accuracy - Training and Validation

Presentamos una precisión durante el entrenamiento. Observamos una mejora continua en el conjunto de entrenamiento, alcanzando valores cercanos al 90%. Sin embargo, la precisión en validación se estanca alrededor del 65%, indicando nuevamente sobreajuste y baja capacidad de generalización.




Figure 3: Precisión del modelo durante entrenamiento y validación.




Figure 5: Matriz de confusión que muestra el desbalanceo en las predicciones.

4.4 AUC - Training and Validation

Se muestra que el valor del AUC (Área bajo la curva ROC) durante el entrenamiento. Al igual que la precisión, el AUC de entrenamiento mejora significativamente, pero el AUC de validación se estabiliza en valores bajos (alrededor de 0.72), indicando una discriminación limitada entre clases en datos no vistos.




Figure 4: Evolución del AUC durante el entrenamiento y validación.

4.6 Curva ROC

La curva ROC refleja una capacidad discriminativa limitada del modelo, con un AUC de 0.650, apenas superior al azar (0.5). Esto confirma que el modelo tiene dificultades para separar adecuadamente las clases.




Figure 6: Curva ROC que muestra un desempeño apenas superior al azar (AUC=0.650).

4.5 Matriz de Confusión

La matriz de confusión muestra que el modelo predice correctamente la mayoría de los casos de explosión (707 de 719), pero falla al identificar la clase "No Explosión", clasificando erróneamente 145 de 182 instancias. Esto revela un fuerte desbalanceo y un sesgo del modelo hacia la clase mayoritaria.

4.7 Predicción de Altura

La Figura presenta una comparación entre las alturas reales y las predichas. La correlación es extremadamente baja (0.036), indicando que el modelo es incapaz de predecir adecuadamente esta variable. Los valores predichos están concentrados en un rango reducido, lo que sugiere que el modelo no está capturando correctamente la variabilidad de los datos.




Figure 7: Relación entre la altura real y la altura predicha por el modelo.

5 Discusión

Los resultados nos revelan hallazgos contraintuitivos: tenemos ausencia de relaciones significativas entre la deformación GNSS y las explosiones, así como entre la sismicidad y la intensidad eruptiva, sugiere limitaciones fundamentales en el enfoque. Una posible explicación radica en la escala temporal utilizada: las ventanas de 14 días podrían ser demasiado amplias para capturar señales precursoras, cuya dinámica crítica ocurre comúnmente en escalas de horas o días. Alternativamente, las características extraídas podrían no reflejar adecuadamente los procesos físicos subyacentes, como interacciones no lineales o patrones temporales de alta frecuencia.

Estas limitaciones destacan lecciones metodológicas críticas. Por un lado, técnicas avanzadas de balanceo de datos como SMOTE o submuestreo estratégico resultan indispensables en conjuntos con desbalance extremo. Por otro lado, la insuficiencia de la regularización para mitigar el sobreajuste apunta a la necesidad de explorar arquitecturas más simples o incluso modelos híbridos que incorporen conocimiento físico. A pesar de estos desafíos, el alto recall en la detección de explosiones cercano al 100%—sugiere que el modelo podría emplearse como un sistema de alerta temprana conservador, donde la prioridad es minimizar falsos negativos aun a costa de falsos positivos.

6 Conclusiones

Se revelan tres limitaciones críticas: Primero un sesgo por desbalanceo de clases (proporción

4:1 entre explosiones/no explosiones) que llevó al modelo a adoptar la estrategia trivial de predecir siempre "Explosión"; Segundo baja capacidad discriminativa ($AUC-ROC = 0.650$), apenas superior al azar; y Tercero fracaso en regresión (correlación de 0.036 para altura eruptiva), sugiriendo que las características no capturan los patrones de intensidad.

No se evidenciaron correlaciones robustas entre la deformación GNSS y las explosiones, ni entre la sismicidad e intensidad eruptiva, lo que plantea dudas sobre la eficacia del enfoque actual. Esto podría deberse a: Primero, ventanas temporales de 14 días demasiado largas para capturar señales precursoras, Después, características que no representan adecuadamente los procesos físicos, o Tres, necesidad de integrar datos adicionales (gas, infrasonido).

7 Referencias

References

- [1] Ayris, P. M. et al. (2023). Global volcanic hazard and risk. *Journal of Volcanology and Geothermal Research*, 435, 107742. <https://doi.org/10.1016/j.jvolgeores.2022.107742>
- [2] Samaniego, P. et al. (2022). The volcanic hazards of the Andean region. *Earth-Science Reviews*, 224, 103887. <https://doi.org/10.1016/j.earscirev.2021.103887>
- [3] Rivera, M. et al. (2021). 460 years of eruptive activity at Ubinas volcano (Peru). *Journal of Volcanology and Geothermal Research*, 412, 107176. <https://doi.org/10.1016/j.jvolgeores.2021.107176>
- [4] Machacca, R. et al. (2023). Sabancaya volcano (Peru): Eruptive activity and impacts. *Journal of South American Earth Sciences*, 124, 104245. <https://doi.org/10.1016/j.jsames.2023.104245>
- [5] Chouet, B. A. & Matoza, R. S. (2022). Seismic monitoring of volcanic activity. *Annual Review of Earth and Planetary Sciences*, 50, 271-299. <https://doi.org/10.1146/annurev-earth-032320-084550>

- [6] Pritchard, M. E. et al. (2022). Satellite geodesy for volcanic hazard assessment. *Nature Reviews Earth & Environment*, 3(12), 827-844. <https://doi.org/10.1038/s43017-022-00363-1>
- [7] Carn, S. A. (2023). Volcanic gas emissions. *Encyclopedia of Geology (2nd ed.)*, 7, 347-359. <https://doi.org/10.1016/B978-0-08-102908-4.00072-5>
- [8] Beyreuther, M. et al. (2020). Machine learning for volcano seismic signals. *Seismological Research Letters*, 91(1), 530-544. <https://doi.org/10.1785/0220190113>
- [9] Corbi, F. et al. (2021). Machine learning for volcano eruption forecasting. *Scientific Reports*, 11, 15513. <https://doi.org/10.1038/s41598-021-94766-5>
- [10] Bosman, K. et al. (2023). Forecasting volcanic eruptions using neural networks. *Journal of Geophysical Research: Solid Earth*, 128, e2022JB025664. <https://doi.org/10.1029/2022JB025664>
- [11] Instituto Geofísico del Perú. (2023). *Catálogo de deformación GNSS de los volcanes Ubinas y Sabancaya* [Dataset]. Portal de Datos Abiertos del Perú. <https://www.datosabiertos.gob.pe/dataset/catálogo-de-deformación-gnss-de-los-volcanes-más-activos-del-perú-ubinas-y-sabancaya-4>
- [12] INGEMMET. (2024). *Catálogo de explosiones de ceniza de los volcanes Ubinas y Sabancaya* [Dataset]. Portal de Datos Abiertos del Perú. <https://www.datosabiertos.gob.pe/dataset/catálogo-de-explosiones-de-ceniza-de-los-volcanes-más-activos-del-perú-ubinas-y-sabancaya>
- [13] Instituto Geofísico del Perú. (2023). *Catálogo de eventos sísmicos de los volcanes Ubinas y Sabancaya* [Dataset]. Portal de Datos Abiertos del Perú. <https://www.datosabiertos.gob.pe/dataset/catálogo-de-eventos-sísmicos-de-los-volcanes-más-activos-del-sur-del-perú-ubinas-y-sabancaya>

A Hiperparametros Parametros

Parámetro	Valor
Optimizador Adam	
Learning rate	0.001
Beta 1	0.9
Beta 2	0.999
Epsilon	1e-8
Gradient clipping	1.0
Regularización	
L2 regularization	0.01
Dropout rate (GNSS/sísmico/fusión)	0.2/0.3/0.2
Entrenamiento	
Batch size	32
Épocas máximas	100
Early stopping patience	15
ReduceLROnPlateau patience	5
Pérdida altura (weight)	0.3
Balanceo de clases	sample_weight

Table 2: Hiperparámetros del modelo organizados por categorías. Se incluyen parámetros de optimización, regularización y estrategias de entrenamiento.

B Diagrama de flujo




Figure 8: Diagrama de flujo del proceso descrito en el paper.

C Código Disponible

El código y los materiales utilizados en este estudio están disponibles en nuestro enlace de repositorio de GitHub: <https://github.com/JefryErick/Metodos-de-Optimizacion>.